

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«КУБАНСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
(ФГБОУ ВО «КубГУ»)

Факультет компьютерных технологий и прикладной математики
Кафедра анализа данных и искусственного интеллекта

КУРСОВАЯ РАБОТА

**КАСТОМИЗАЦИЯ И ПЕРСОНАЛИЗАЦИЯ БОЛЬШИХ ЯЗЫКОВЫХ
МОДЕЛЕЙ И ИИ-АГЕНТОВ**

Работу выполнил _____ И.В. Селиванов
(подпись)

Направление подготовки 09.04.03 Прикладная информатика курс 1
(код, наименование)

Направленность (профиль) Искусственный интеллект и машинное обучение

Научный руководитель
д-р техн. наук, проф. _____ А.В. Коваленко
(подпись, дата)

Нормоконтролер
канд. физ.-мат. наук, доцент _____ Г.В. Калайдина
(подпись, дата)

Краснодар
2026

СОДЕРЖАНИЕ

Введение	3
1 Теоретические основы кастомизации и персонализации больших языковых моделей и ИИ-агентов.....	5
1.1 Подходы к адаптации языковых моделей под задачу и пользователя	5
1.2 Подготовка данных как основа кастомизации.....	8
1.3 Представление знаний и архитектура системы	10
2 Конвейер дистилляции и структуризации документов	13
2.1 Дистилляция документов мультимодальной OCR-моделью	13
2.2 Структуризация извлечённых данных средствами больших языковых моделей.....	16
2.3 Ролевое взаимодействие агентов при работе с базой знаний.....	18
3 Программная реализация и апробация	21
3.1 Программное решение для подготовки данных	21
3.2 Апробация конвейера.....	23
3.3 Ограничения и направления развития.....	27
Заключение.....	30
Список использованных источников.....	32
Приложение А Примеры представления атомарных сущностей.....	37
Приложение Б Ролевые инструкции ИИ-агентов.....	38

ВВЕДЕНИЕ

Современный этап развития искусственного интеллекта характеризуется широким распространением больших языковых моделей. Они применяются для генерации и анализа текстов, ответов на вопросы, программирования и автоматизации интеллектуальной работы. Вместе с тем универсальные модели обучаются на общедоступных данных и потому не учитывают ни специфику предметной области, ни терминологию, задачи и накопленные материалы конкретного пользователя. Преодоление этого разрыва составляет содержание кастомизации и персонализации языковых моделей и построенных на них ИИ-агентов.

Актуальность темы определяется тем, что решающим фактором успешной персонализации оказываются не сами модели, а данные, которыми они оперируют. По статистике, значительная часть проектов в области искусственного интеллекта оказывается под угрозой срыва из-за отсутствия данных, готовых к использованию ИИ. При этом значительная доля знаний существует в виде документов PDF, сканированных страниц и фотографий, недоступных для непосредственной обработки языковыми моделями. Настоящая работа посвящена автоматическому превращению таких документов в структурированные базы знаний.

Объектом исследования является процесс кастомизации и персонализации больших языковых моделей и ИИ-агентов на основе данных, подготовленных для работы с искусственным интеллектом.

Предметом исследования являются методы дистилляции и структуризации неоднородных документов для формирования базы знаний персонализированных ИИ-систем.

Цель работы состоит в проектировании конвейера дистилляции и структуризации документов, объединяющего мультимодальную модель оптического распознавания и большие языковые модели, и в программной реализации и апробации его головного этапа.

Для достижения поставленной цели поставлены следующие задачи:

- изучить подходы к адаптации больших языковых моделей под задачу и пользователя;
- проанализировать требования к подготовке данных и способы представления знаний в персонализированных системах;
- спроектировать конвейер дистилляции и структуризации документов;
- спроектировать ролевое взаимодействие ИИ-агентов с базой знаний;
- реализовать программное решение для головного этапа конвейера, то есть извлечения содержимого документов и работы с файлами;
- провести апробацию реализованного этапа и определить ограничения и направления развития конвейера.

Методы исследования включают анализ и обобщение научных публикаций, сравнительный анализ подходов и инструментов, проектирование архитектуры системы, программную реализацию и экспериментальную проверку на реальном документе.

Практическая значимость работы состоит в создании работоспособного программного решения, которое превращает неоднородные документы в данные, подготовленные для работы с ИИ, и применимо для построения персонализированных баз знаний.

В первой главе сравниваются подходы к адаптации языковых моделей, обосновывается роль подготовки данных и рассматриваются способы представления знаний и архитектура персонализированных систем.

Во второй главе описывается предлагаемый конвейер: выбор мультимодальной модели распознавания, слой структуризации знаний и ролевая схема взаимодействия агентов с базой знаний.

В третьей главе представлены программная реализация головного этапа конвейера, результаты его апробации, а также ограничения и направления развития.

В заключении подведены итоги работы и определены перспективы использования полученных результатов.

1 Теоретические основы кастомизации и персонализации больших языковых моделей и ИИ-агентов

1.1 Подходы к адаптации языковых моделей под задачу и пользователя

Большие языковые модели (далее БЯМ) представляют собой нейронные сети, обученные на обширных текстовых корпусах предсказывать продолжение текста, и строятся на архитектуре трансформера [13]. Задача языкового моделирования относится к числу центральных задач обработки естественного языка [20]. Лежащие в основе БЯМ методы глубокого обучения подробно изложены в фундаментальных руководствах [1, 6]. Эмпирически установлено, что качество таких моделей закономерно растёт с увеличением числа параметров, объёма обучающих данных и вычислений [30]. Благодаря масштабному предобучению модели приобретают широкие языковые и фактические знания, которые позволяют им решать разнообразные задачи без специальной настройки: способность справляться с новой задачей по нескольким примерам прямо в запросе была продемонстрирована уже на модели GPT-3 [21]. Современные БЯМ применяются для генерации и анализа текстов, ответов на вопросы, программирования и автоматизации интеллектуальной работы [8].

Вместе с тем универсальность предобученных моделей оборачивается двумя принципиальными ограничениями. Во-первых, знания модели зафиксированы на момент окончания обучения и не включают ни свежих событий, ни внутренних документов конкретной организации. Во-вторых, модель ничего не знает о конкретном пользователе: его терминологии, задачах, предпочтениях и накопленных материалах. Преодоление этих ограничений составляет суть кастомизации и персонализации. Под кастомизацией в настоящей работе понимается адаптация модели к предметной области и задаче, а под персонализацией приспособление её поведения к конкретному пользователю и его данным [10].

Первым и наиболее доступным подходом к адаптации является промптинг, то есть управление поведением модели через текстовые инструкции. В инструкции задаются роль модели, правила ответа, терминология и примеры решения задачи. Подход не требует изменения модели и применяется мгновенно, однако объём передаваемых знаний ограничен размером контекстного окна, а сами знания приходится передавать при каждом обращении заново. Сама способность моделей следовать инструкциям формируется дообучением на примерах выполнения инструкций с учётом обратной связи человека [32]. Действенным приёмом промптинга является также построение цепочки рассуждений, при котором модель просят выписывать промежуточные шаги решения, что заметно повышает качество на сложных задачах [15].

Второй подход состоит в подключении внешней базы знаний через механизм генерации с дополнением результатами поиска (Retrieval-Augmented Generation, RAG), предложенный для задач, требующих интенсивной работы со знаниями [28]. Принцип работы подхода представлен на рисунке 1.



Рисунок 1 – Принцип работы генерации с дополнением результатами поиска (составлено автором)

Как показано на рисунке 1, ответ модели строится на фрагментах, найденных в базе знаний по запросу пользователя. Такой подход обеспечивает актуальность знаний без переобучения модели, снижает количество ошибочных утверждений и делает ответы проверяемыми, поскольку каждый

ответ опирается на конкретные источники [4]. Это особенно важно с учётом того, что склонность языковых моделей порождать правдоподобные, но недостоверные утверждения хорошо документирована [31].

Третий подход заключается в дообучении модели на целевых данных. Парадигма предобучения с последующим дообучением под конкретную задачу была закреплена в работах о модели BERT [14]. Полное дообучение изменяет все веса модели и требует значительных вычислительных ресурсов и большого размеченного корпуса. Альтернативой выступают параметро-эффективные методы, прежде всего низкоранговая адаптация (Low-Rank Adaptation, LoRA), при которой обучается лишь небольшая добавка к весам модели [23]. К этому же семейству относится настройка непрерывных подсказок, при которой обучаются только векторные представления инструкции [22]. Экспериментальные исследования показывают, что низкоранговая адаптация достигает качества, сопоставимого с полным дообучением, при кратно меньших затратах ресурсов [3]. Тем не менее даже эффективное дообучение требует подготовленного корпуса данных, а обновление знаний влечёт повторное обучение.

Сравнительная характеристика трёх подходов приведена в таблице 1.

Таблица 1 – Сравнение подходов к адаптации больших языковых моделей

Критерий	Промптинг	RAG	Дообучение (LoRA)
Затраты на внедрение	минимальные	средние	высокие
Изменение весов модели	нет	нет	да
Обновление знаний	правка инструкции	пополнение базы знаний	повторное обучение
Проверяемость источников ответа	ограниченная	высокая	отсутствует
Требования к данным	примеры в инструкции	структурированная база знаний	размеченный корпус
Глубина адаптации	поверхностная	средняя	глубокая

Источник: составлено автором.

Перечисленные подходы не исключают, а дополняют друг друга, они различаются глубиной адаптации, стоимостью и характером требований к данным. Заметим, что в каждом из подходов решающим фактором оказываются не веса модели, а данные, которыми она оперирует.

В настоящей работе основным подходом выбрано сочетание подключаемой базы знаний и промптинг. База знаний обеспечивает доступ модели к материалам пользователя и проверяемость ответов, а инструкции задают роли агентов и правила работы. Дообучение не применяется, поскольку знания пользователя постоянно пополняются, и переобучение модели при каждом обновлении было бы неоправданно затратным.

Таким образом, центральной задачей становится превращение разрозненных материалов пользователя в качественную базу знаний.

1.2 Подготовка данных как основа кастомизации

Выбор подходов, опирающихся на внешние знания, переносит центр тяжести с модели на данные. Качество и подготовка данных оказываются узким местом интеллектуальных систем, недостаточная проработка данных на ранних этапах вызывает каскадные сбои в дальнейшей работе [16]. Согласно отраслевой оценке аналитической компании Gartner (пресс-релиз), значительная часть проектов в области искусственного интеллекта оказывается под угрозой срыва именно из-за отсутствия данных, готовых к использованию ИИ [18]. В связи с этим в отрасли сформировалось понятие данных, подготовленных для работы с ИИ (AI-ready data): это данные, обладающие качественной структурой, явными связями между элементами, управляемой детализацией и возможностью адресного доступа [18].

Для персонализации недостаточно просто накопить документы. Неструктурированный массив текстов плохо поддаётся поиску, содержит дублирующиеся и противоречивые формулировки, а его фрагменты лишены контекста. Исследования персонализированных ИИ подтверждают, что

качество персонализации определяется не только профилем пользователя, но и организацией внутреннего представления его знаний [10].

Особую сложность представляет исходная форма пользовательских материалов. Значительная часть знаний организаций и частных пользователей существует в виде документов PDF, сканированных страниц, фотографий и презентаций. Такие источники содержат информацию в визуальной форме, которая недоступна для непосредственной обработки поисковыми и генеративными алгоритмами. Следовательно, подготовка данных начинается с извлечения содержимого из неоднородных документов.

Подготовка данных для персонализированных ИИ-систем включает шесть последовательных этапов, представленных на рисунке 2.



Рисунок 2 – Этапы подготовки данных для работы с ИИ
(составлено автором)

Принципиально, что качество подготовки важнее объёма – компактная, но хорошо организованная база знаний даёт более точные ответы, чем обширный, но хаотичный массив текстов.

Таким образом, подготовка данных является фундаментом кастомизации. Именно она определяет, какие знания и в какой форме будут доступны модели. Перечисленные операции реализуются конвейером дистилляции и структуризации документов, который рассматривается во второй главе настоящей работы.

1.3 Представление знаний и архитектура системы

Эффективность базы знаний определяется выбранным способом представления знаний. Простейшим вариантом является разбиение текста на фрагменты фиксированной длины с последующим поиском по ним. Такой способ легко реализуется, однако границы фрагментов проводятся механически и часто разрывают смысловые единицы, а связи между фрагментами никак не фиксируются.

Более зрелым решением является атомарное представление знаний, при котором единицей хранения служит самодостаточный осмысленный фрагмент: определение, утверждение, таблица, иллюстрация с описанием. Атомарные единицы дополняются терминологическим глоссарием, который выравнивает терминологию и снимает неоднозначность, и тематическим рубрикатором, который образует навигационный слой над массивом знаний. Поиск по такой базе опирается на векторные представления текста, позволяющие находить материалы по смысловой близости, а не только по совпадению слов [27].

Дальнейшим развитием являются графы знаний и онтологии, в которых сущности и связи между ними описываются явно. Отечественные исследования демонстрируют работоспособность автоматического построения графов знаний из коллекций научных документов на основе предметной онтологии [5]. Применительно к языковым моделям графовый подход реализуется в семействе методов GraphRAG: исходный метод был предложен для ответов на вопросы, охватывающие весь массив документов целиком [17]. Разновидности этого подхода активно развиваются в задачах кастомизации БЯМ [9]. Платой за выразительность являются затраты на построение и сопровождение графа, поэтому переход к графовому представлению целесообразен по мере роста базы знаний. Рассмотренные способы образуют последовательные ступени развития представления знаний, показанные на рисунке 3.




Рисунок 3 – Развитие способов представления знаний
(составлено автором)

Архитектура персонализированной ИИ-системы строится на нескольких принципах. Принцип модульности требует разделять систему на независимые компоненты: извлечение содержимого, структуризацию, хранение, поиск и генерацию ответов. Принцип единственной ответственности закрепляет за каждым компонентом одну задачу, что упрощает контроль качества и замену отдельных частей. Наконец, принцип поэтапного раскрытия контекста предписывает передавать модели только те знания, которые необходимы для текущего шага: контекстное окно модели является ограниченным ресурсом, и его экономное использование напрямую влияет на качество ответов [12]. Экспериментально показано, что модели заметно хуже используют сведения, расположенные в середине длинного контекста, что дополнительно подчёркивает ценность строгого отбора материалов [24].

Перечисленные принципы естественно приводят к многоагентной архитектуре, в которой система складывается из специализированных агентов, взаимодействующих между собой. Современные обзоры показывают, что мультиагентные системы на основе БЯМ превосходят одноагентные в задачах, требующих разделения труда и работы с большими объёмами материалов [2]. Для работы с базой знаний такое разделение означает выделение отдельных ролей поиска и анализа, что подробно рассматривается в подразделе 2.3.

Таким образом, теоретический анализ определяет облик разрабатываемого решения: адаптация БЯМ строится на подключаемой базе знаний и промптинге, основой служат данные, подготовленные для работы с ИИ, представление знаний опирается на атомарные единицы с глоссарием и рубрикатором с перспективой перехода к графовому представлению, а архитектура системы является модульной и многоагентной. Практическая реализация этих положений начинается с конвейера дистилляции и структуризации документов, которому посвящена следующая глава.

2 Конвейер дистилляции и структуризации документов

2.1 Дистилляция документов мультимодальной OCR-моделью

Предлагаемый конвейер обработки неоднородных документов последовательно решает три задачи: извлечение содержимого документа мультимодальной моделью оптического распознавания, структуризацию извлечённых данных средствами больших языковых моделей и организацию доступа к полученной базе знаний через ролевое взаимодействие ИИ-агентов. Общая схема конвейера представлена на рисунке 4.




Рисунок 4 – Конвейер дистилляции и структуризации документов
(составлено автором)

Под дистилляцией документов в настоящей работе понимается превращение исходного документа в набор типизированных атомарных сущностей, пригодных для индексации, навигации и адресного использования. Документы в формате PDF, сканированные страницы и фотографии содержат информацию в форме, недоступной для

непосредственной обработки алгоритмами поиска и генерации текста, поэтому первым этапом конвейера является извлечение содержимого.

Термин «дистилляция» употребляется здесь в значении информационной дистилляции (information distillation) и опирается на сложившееся в обработке естественного языка словоупотребление, при котором под дистилляцией понимается выделение из источника компактного, неизбыточного содержательного ядра; эта линия восходит к оценочным задачам по извлечению содержания текста и в дальнейшем развивалась в работах по экстрактивному реферированию [11]. В отличие от запросо-ориентированной постановки, где из связного текста отбираются готовые предложения, в настоящей работе понятие распространяется на разбор документа: вместо отбора предложений выполняется распознавание и реструктуризация содержимого в набор типизированных атомарных сущностей, поэтому операционализация термина является авторской. Указанное значение не следует смешивать с дистилляцией знаний (knowledge distillation) в обучении нейросетей, где знания переносятся от модели-учителя к модели-ученику; к настоящей работе дистилляция знаний отношения не имеет.

Классические системы оптического распознавания символов (OCR) решают задачу посимвольного перевода изображения в текст, однако при этом теряется структура документа: порядок чтения колонок, границы таблиц, связи подписей с иллюстрациями, математические формулы. Для последующей работы БЯМ такая потеря критична, поскольку именно структура определяет смысловые границы фрагментов знаний.

Современные мультимодальные модели разбора документов устраняют этот недостаток: они анализируют макет страницы целиком, определяют семантическую роль каждой области (заголовки, абзац, таблица, формула, иллюстрация, подпись) и восстанавливают правильный порядок чтения. В качестве базовой модели конвейера выбрана модель PaddleOCR-VL-1.5, которая объединяет модуль анализа макета страницы, визуальный

кодировщик и компактный языковой декодер и при этом содержит всего 0,9 млрд параметров [25].

Выбор модели обоснован результатами на эталонном наборе OmniDocBench v1.5, который оценивает качество разбора документов по распознаванию текста, формул, таблиц и порядка чтения. Результаты ведущих моделей приведены в таблице 2.

Таблица 2 – Результаты мультимодальных моделей разбора документов на эталонном наборе OmniDocBench v1.5 [25]

Модель	Класс решения	Интегральный балл
PaddleOCR-VL-1.5	открытая, 0,9 млрд парам.	94,5
PaddleOCR-VL	открытая, 0,9 млрд парам.	92,9
MinerU2.5	открытая, 1,2 млрд парам.	90,7
Gemini-3 Pro	закрытая облачная	90,3
Qwen3-VL-235B-A22B	открытая, 235 млрд парам.	90,0
Gemini-2.5 Pro	закрытая облачная	89,6
GPT-5.2	закрытая облачная	85,5
Marker-1.8.2	программный конвейер	71,3

Источник: составлено по данным [25].

По данным разработчиков, компактная открытая модель показывает интегральный балл на уровне или выше ведущих закрытых облачных решений и значительно более крупных открытых моделей. Для настоящей работы принципиально именно сочетание свойств: малый размер модели (0,9 млрд параметров) делает её вычислительно доступной и позволяет развёртывать решение локально, что важно при обработке конфиденциальных документов организации.

Приведённые в таблице 2 значения опубликованы разработчиками модели PaddleOCR-VL-1.5 в препринте [25] и получены их собственными измерениями, поэтому являются заявленными авторами модели, а не независимым свидетельством её качества; строгий вывод требует независимого воспроизведения результатов. Сам эталонный набор

OmniDocBench при этом разработан сторонней командой (OpenDataLab, Shanghai AI Lab).

Отдельным преимуществом выбранной модели является устойчивость к физическим искажениям документов, показанная разработчиками по результатам дополнительного набора испытаний Real5-OmniDocBench: модель сохраняет качество распознавания при артефактах сканирования, перекосе страницы, деформации бумаги, съёмке с экрана и неравномерном освещении [25]. Эти условия типичны для реальных архивов, в которых значительная часть материалов существует в виде сканов и фотографий.

В результате дистилляции документ разделяется на атомарные сущности трёх типов. Текстовые блоки экспортируются в текстовом формате с сохранением структуры заголовков, изображения сохраняются как самостоятельные визуальные объекты, таблицы преобразуются в структурированный табличный формат. Каждая сущность получает привязку к исходному документу и странице, что обеспечивает проверяемость дальнейших ответов системы. Примеры представления сущностей всех трёх типов приведены в приложении А.

Таким образом, этап дистилляции превращает разнородный массив документов в коллекцию машиночитаемых сущностей. Однако само по себе извлечение содержимого ещё не делает знания пригодными для персонализированной работы ИИ-систем: для этого необходим следующий этап конвейера.

2.2 Структуризация извлечённых данных средствами больших языковых моделей

Результат оптического распознавания представляет собой набор разрозненных фрагментов, в котором отсутствуют смысловые связи, единая терминология и средства навигации. Для персонализации БЯМ и ИИ-агентов недостаточно просто накопить документы: критически важны качество структуры, явные связи между сущностями, управляемая детализация и

возможность адресного доступа к знаниям [18]. Исследования персонализированных языковых моделей также показывают, что персонализация должна опираться не только на профиль пользователя, но и на чётко организованное внутреннее представление знаний [10].

Задачу организации знаний в конвейере решает слой структуризации, построенный на БЯМ. В отличие от модели распознавания, которая работает с визуальным представлением страницы, языковая модель работает со смыслом фрагментов. Состав операций слоя структуризации представлен на рисунке 5.



Рисунок 5 – Слой структуризации знаний (составлено автором)

Показанные на рисунке 5 операции переводят коллекцию фрагментов в структурированную базу знаний. Классификация относит каждый фрагмент к содержательной области, глоссарий снижает риск противоречивых формулировок, атомарное представление позволяет переиспользовать мелкие осмысленные фрагменты в разных сценариях, а рубрикатор даёт возможность находить материалы по теме, а не только по точному совпадению слов.

Для получения структурированных знаний языковой модели используется механизм генерации с дополнением результатами поиска (Retrieval-Augmented Generation, RAG). При ответе на запрос система сначала находит в базе знаний релевантные сущности, а затем передаёт их модели в качестве контекста. Разновидности этого механизма, от простых схем до

модульных решений, систематизированы в современных обзорах [29]. В качестве перспективного расширения рассматривается графовый подход GraphRAG, который строит явную модель связей между сущностями и использует эти структуры при поиске [9]. Графовое представление особенно полезно там, где вопрос требует связать разрозненные фрагменты информации или сделать вывод по всему массиву материалов целиком.

Разделение функций дистилляции и структуризации между двумя специализированными моделями обусловлено принципиальными различиями в характере задач. Модель распознавания решает задачу восприятия: она преобразует визуальное представление страницы в машиночитаемые данные. Языковая модель решает задачу понимания: она определяет семантическую роль фрагмента, его место в тематической иерархии и связи с другими сущностями. Объединение этих компонент в единый конвейер обеспечивает одновременно точность извлечения и глубину организации знаний.

Таким образом, слой структуризации формирует из извлечённых сущностей базу знаний с навигацией, единой терминологией и адресным доступом. Остаётся определить, каким образом эта база будет использоваться при ответах на запросы пользователя.

2.3 Ролевое взаимодействие агентов при работе с базой знаний

Под ИИ-агентом в настоящей работе понимается языковая модель, которая наделена определённой ролью, имеет доступ к инструментам и самостоятельно планирует последовательность действий для решения задачи. Такое понимание согласуется с классической трактовкой интеллектуального агента как системы, которая воспринимает среду и действует в ней для достижения поставленной цели [7]. Практической основой агентного поведения БЯМ служит чередование рассуждений и обращений к инструментам, предложенное в подходе ReAct [26]. Выразительные возможности агентов на основе БЯМ демонстрируют эксперименты с

генеративными агентами, воспроизводящими правдоподобное поведение в модельной среде [19]. Применительно к работе с базой знаний агентный подход позволяет отделить поиск информации от её анализа.

Использование единственного универсального агента для всех операций приводит к смешению ролей: один и тот же контекст вынужден вмещать и результаты поиска, и промежуточные рассуждения, и формирование ответа. Вместо этого в конвейере применяется ролевая декомпозиция, при которой каждый агент отвечает за собственную область действий. Такое разделение соответствует принципу единственной ответственности, упрощает контроль поведения системы и снижает взаимные помехи между задачами.

Первым элементом ролевой схемы является агент-библиотекарь. Он выполняет поиск, фильтрацию и первичную организацию сущностей из базы знаний: находит материалы по запросу, отбрасывает нерелевантные фрагменты и упорядочивает отобранное. Принципиально, что библиотекарь не формирует содержательного ответа: его результатом является компактная подборка проверенных источников.

Вторым элементом является агент-исследователь. Он получает уже отобранный набор сущностей и строит на его основе аналитический вывод или ответ на запрос пользователя. Поскольку исследователь работает только с ограниченным и качественным материалом, его рассуждения опираются на проверенные фрагменты, а не на весь неоднородный массив документов. Тексты ролевых инструкций обоих агентов приведены в приложении Б.

Схема ролевого взаимодействия агентов представлена на рисунке 6.




Рисунок 6 – Ролевое взаимодействие агентов при работе с базой знаний (составлено автором)

Описанное разделение реализует принцип поэтапного раскрытия контекста. Система сначала находит необходимое, и только затем отдельный агент работает с ограниченным набором материалов. Агент поиска передаёт в контекст генерации только релевантные фрагменты, что снижает информационный шум и экономит контекстное окно модели [12]. В результате качество ответа определяется качеством отбора, а не объёмом загруженных в модель данных.

Таким образом, конвейер обеспечивает полный путь от исходного документа до персонализированного ответа ИИ-системы: дистилляция выделяет атомарные сущности, структуризация организует их в базу знаний, а ролевое взаимодействие агентов доставляет знания пользователю. Программная реализация описанного конвейера и результаты его апробации рассматриваются в следующей главе.

3 Программная реализация и апробация

3.1 Программное решение для подготовки данных

Программная часть работы опирается на три различных слоя. Используются готовые компоненты: мультимодальная модель PaddleOCR-VL-1.5 [25], выполняющая разбор страниц, и готовая вопросно-ответная система, привлечённая только для демонстрации применимости подготовленных данных (раздел 3.2, рисунок 9). Самостоятельно разработаны архитектура конвейера дистилляции, типизация сущностей и схема их полей, а также веб-приложение головного этапа: постраничная обработка документа с отображением хода, выгрузка результатов в трёх форматах и ведение истории обработанных документов. Спроектированы, но в рамках курсовой работы не реализованы слой структуризации (раздел 2.2) и ролевая схема взаимодействия агентов (раздел 2.3); их разработка вынесена в выпускную квалификационную работу. Тем самым научная новизна, связанная со структуризацией извлечённого содержимого и ролевой декомпозицией работы с базой знаний, относится к дальнейшему исследованию, а в настоящей работе спроектирован конвейер в целом и реализован, апробирован его головной этап дистилляции содержимого документов и работы с файлами.

По результатам анализа предметной области были сформулированы следующие требования к программному решению:

- загрузка документов в форматах PDF, PNG, JPEG и TIFF объёмом до 50 МБ;
- постраничное распознавание документа мультимодальной моделью с отображением хода обработки;
- разделение содержимого на сущности трёх типов: текстовые блоки, изображения и таблицы;
- выгрузка результатов в форматах, пригодных для дальнейшей обработки: текст с разметкой, архив изображений и табличные файлы;

– ведение истории обработанных документов с возможностью возврата к результатам.

В соответствии с требованиями разработано веб-приложение для подготовки данных.

Серверная часть приложения выполняет разбор документов моделью PaddleOCR-VL-1.5 и формирует выходные файлы, а клиентская часть предоставляет пользователю интерфейс загрузки, контроля и выгрузки результатов. Главный экран приложения представлен на рисунке 7.




Рисунок 7 – Главный экран программного решения (составлено автором)

Интерфейс разделён на функциональные области в соответствии с этапами работы. Область загрузки принимает файл и проверяет его формат, область состояния отображает ход распознавания по страницам, а область результата позволяет просматривать распознанные страницы и выгружать материалы. Для выгрузки доступны три формата, соответствующие трём типам сущностей: текст с разметкой, архив изображений и архив таблиц в формате электронных таблиц.

Результат распознавания и журнал обработанных документов представлены на рисунке 8. Распознанный текст сохраняет структуру исходной страницы: заголовки, абзацы, подписи к иллюстрациям и сами иллюстрации воспроизводятся в правильном порядке чтения.




Рисунок 8 – Результат распознавания и журнал обработки
(составлено автором)

Таким образом, головной этап конвейера, то есть дистилляция содержимого документа и работа с файлами, реализован полностью: документ превращается в набор типизированных сущностей. Их структуризация и загрузка в базу знаний относятся к спроектированным, но пока не реализованным слоям конвейера.

3.2 Апробация конвейера

Апробация конвейера выполнена на двух профессиональных руководствах со сложной вёрсткой, в русском и английском изданиях каждого: руководстве по бизнес-анализу (BAВОК, около 514 страниц в английском издании и около 615 в русском) и руководстве по управлению

проектами (PMBOOK, шестая редакция, около 756 и около 762 страниц соответственно). Все четыре издания обработаны полностью, суммарный объём превышает 2600 страниц. Источники содержат многоуровневые заголовки, таблицы, матрицы, схемы и подписи к иллюстрациям, что делает их представительной нагрузкой для проверки этапа извлечения на документах разного языка и объёма. Проверка носила качественный характер и была направлена на оценку работоспособности конвейера, корректности разделения сущностей и применимости выбранной модели к реальным документам. Приведённые далее числа описывают характеристики демонстрационного прогона, то есть параметры самой обработки, а не показатели качества извлечения; критерии оценки качества и базовая линия для сравнения в настоящей работе не вводятся, методика измерения вынесена в раздел 3.3.

Извлечение содержимого выполнено успешно для всех изданий. Основным практическим ограничением оказалась пропускная способность по числу запросов в секунду – страницы подавались на обработку через очередь запросов, поэтому полная обработка книги занимала заметно больше времени, чем единичный запрос; на качество разбора это ограничение не влияло и затрагивало только скорость.

На этих источниках конвейер корректно выделил информационные слои: текстовые фрагменты экспортированы с сохранением иерархии заголовков, таблицы преобразованы в табличный формат, иллюстрации сохранены как отдельные файлы с привязкой к страницам. Визуальная проверка распознанных страниц показала корректное воспроизведение порядка чтения и подписей к рисункам, что видно на рисунке 8.

Для проверки применимости подготовленных данных был развёрнут демонстрационный сценарий на основе подключаемой базы знаний: извлечённые материалы загружались в систему вопросно-ответного взаимодействия, после чего системе задавались вопросы по содержанию источника. Пример ответа представлен на рисунке 9.




Рисунок 9 – Демонстрационный сценарий работы с базой знаний (составлено автором)

Как видно из рисунка 9, система формирует структурированный ответ на вопрос пользователя и сопровождает каждое утверждение ссылкой на фрагмент источника, что обеспечивает проверяемость ответов.

Демонстрационный сценарий показал на одном примере, что данные, подготовленные конвейером, в принципе пригодны для персонализированной работы языковой модели; систематическая проверка пригодности выходит за рамки демонстрации.

Главным содержательным результатом апробации стал вывод об узком месте системы. Этап дистилляции показал высокое качество и не потребовал доработок, тогда как этап структуризации оказался наиболее требовательным к проектным решениям: навигация по извлечённым сущностям, приоритизация контекста и маршрутизация материалов между агентами требуют дополнительной проработки.

Иными словами, ограничивающим фактором является не распознавание документов, а организация извлечённого знания.

Чтобы оценить границы применимости этапа извлечения, распознанные страницы обоих руководств были просмотрены вручную и сопоставлены с исходными разворотами. Наблюдения носят качественный характер и относятся к использованным изданиям, поэтому отражают поведение конвейера на конкретном материале, а не его обобщённую точность. Распознавание текста на этом материале оказалось надёжным, тогда как основные расхождения касались не символического распознавания, а восстановления структуры сложных элементов страницы. Типы элементов, представляющие для извлечения наибольший риск, сведены в таблице 3.

Таблица 3 – Типология предельных случаев этапа извлечения

Тип элемента	Характер возможного расхождения	Влияние на дальнейшую обработку
Сложные и вложенные таблицы с объединёнными ячейками	при линейной выгрузке теряется отношение подчинённости между ячейками и строками, заголовки отрываются от данных	структуру приходится восстанавливать на следующем слое
Многоколоночная вёрстка и боковые врезки	порядок чтения местами определяется неверно, текст соседних колонок чередуется	абзацы выстраиваются не в исходной последовательности
Колонтитулы, номера разделов и сноски	повторяющиеся служебные элементы иногда попадают в основной поток текста	требуется фильтрация служебного текста перед структуризацией
Формулы и специальные обозначения	в деловых руководствах встречаются редко, на отдельных вставках символы передаются неточно	локальные искажения, основной текст не затрагивают
Низкокачественные и рукописные сканы	в использованных электронных изданиях не встречались	устойчивость к таким искажениям на собственном материале не проверялась

Источник: составлено автором.

Наиболее уязвимыми оказались страницы с таблицами, содержащими объединённые по вертикали ячейки, которыми насыщены оба руководства. Объединённая ячейка-заголовок разворачивалась в одиночный фрагмент текста, из-за чего подчинённость строк терялась, и табличная запись

превращалась в плоский перечень значений. Текстовое содержание ячеек при этом сохранялось, однако связи между ними приходилось бы восстанавливать средствами слоя структуризации.

Вторая группа расхождений связана с многоколоночными врезками и боковыми колонками. При определении порядка чтения строки соседних колонок местами чередовались, и связный фрагмент распадался на перемешанные куски. Для делового руководства это давало локальные нарушения последовательности абзацев, не искажая их содержания. Реже служебные элементы страницы, колонтитулы и номера разделов, попадали в основной поток текста отдельными короткими строками; такой шум отделяется простой очисткой, но требует отдельного шага перед структуризацией.

Таким образом, расхождения касались в первую очередь восстановления структуры документа, а не распознавания символов: связный текст воспроизводился надёжно, тогда как сложная табличная и многоколоночная вёрстка и служебные элементы страницы требовали внимания. Отдельно отмечу, что использованные издания являлись электронными, поэтому устойчивость модели к артефактам сканирования и съёмки на собственном материале не проверялась и опирается только на данные разработчиков. Эти наблюдения уточняют вывод об узком месте – основная нагрузка ложится не на распознавание, а на восстановление структуры и организацию извлечённого знания, а границы применимости подробнее рассматриваются в разделе 3.3.

3.3 Ограничения и направления развития

Текущий этап работы имеет ряд ограничений, которые следует учитывать при оценке результатов.

Во-первых, апробация выполнена на малом количестве источников и носила качественный характер. Статистически значимые выводы о качестве извлечения потребуют проверки на представительном наборе документов.

Во-вторых, конвейер обрабатывает только изображения и документы PDF, модули обработки аудио- и видеоматериалов отсутствуют.

В-третьих, ряд архитектурных решений слоя структуризации, включая графовое представление знаний, находится на стадии сравнения гипотез.

Качественный характер пилотной проверки задаёт и метод её последующего уточнения. В дальнейшей работе качество извлечения предполагается оценивать количественно по нескольким метрикам: полноте и точности распознавания текста, качеству восстановления таблиц по метрике TEDS (древовидная мера схожести структуры таблицы) и точности восстановления порядка чтения элементов страницы. Эти метрики соответствуют аспектам, по которым оценивает модели эталонный набор OmniDocBench v1.5, что обеспечивает сопоставимость собственных измерений с опубликованными.

Чтобы оценка была содержательной, результат конвейера предстоит сравнивать с базовой оценкой. В её роли выступают классический послойный путь распознавания, в котором определение макета страницы и распознавание символов выполняются отдельными модулями, и готовый конвейер преобразования документов PDF в формат Markdown – инструмент Marker компании Datalab. Этот инструмент уже приведён в таблице 2 как программный конвейер разбора документов и сопоставлен с выбранной моделью, поэтому служит естественной точкой отсчёта. На оценочном наборе документов сравнение предстоит воспроизвести в собственных условиях.

Границы применимости реализованного этапа задаются типами страниц, на которых извлечение давало расхождения – сложная и вложенная табличная вёрстка, многоколоночные развороты и служебные элементы страницы. Именно на этих классах документов измерение метрик в дальнейшей работе наиболее показательны.

Для узкого места системы, слоя структуризации, предлагается измеримый критерий качества: доля корректно типизированных и корректно связанных сущностей, вычисляемая на размеченном эталоне. Эталонная разметка готовится вручную на репрезентативной подвыборке документов, а критерий определяется как отношение числа верно классифицированных и верно связанных сущностей к их общему числу. Подготовку эталонной разметки и само измерение автор относит к выпускной квалификационной работе, где слой структуризации будет реализован.

Перечисленные ограничения определяют направления дальнейшего развития. Ближайшим шагом является массовая обработка полного массива документов пользователя и доработка слоя структуризации, а именно связывание сущностей, нормализация терминологии и построение устойчивой навигации.

Следующим направлением выступает переход к графовому представлению знаний на основе подходов GraphRAG, который позволит отвечать на вопросы, требующие связывания разрозненных фрагментов [9].

Отдельным направлением является расширение состава модальностей. Добавление обработки аудио- и видеоматериалов позволит собирать единое мультимодальное представление знаний из лекций, встреч и учебных записей.

Наконец, перспективным направлением развития агентного слоя является переход к расширяемой архитектуре, в которой роли агентов, подключаемые инструменты и сценарии работы описываются декларативно и могут настраиваться под задачу без изменения ядра системы.

Такая архитектура открывает путь к практическому внедрению решения и его развитию в самостоятельный программный продукт.

Таким образом, программная реализация подтвердила работоспособность головного этапа конвейера, апробация выявила приоритет развития слоя структуризации, а сформулированные направления задают план дальнейшей работы над системой.

ЗАКЛЮЧЕНИЕ

В результате проведённой работы спроектирован конвейер дистилляции и структуризации документов, объединяющий мультимодальную модель оптического распознавания и большие языковые модели для персонализации ответов и поведения ИИ-агентов, а его головной этап извлечения содержимого документов и работы с файлами реализован и апробирован. Слой структуризации и ролевое взаимодействие агентов разработаны на уровне проектирования и вынесены в дальнейшую работу. Цель работы достигнута, поставленные задачи решены.

В теоретической части работы изучены подходы к адаптации больших языковых моделей под задачу и пользователя. Сравнительный анализ промптинга, подключаемых баз знаний и дообучения показал, что подходы различаются глубиной адаптации и требованиями к данным, при этом во всех случаях решающим фактором являются не веса модели, а качество данных, которыми она оперирует. Обоснован выбор сочетания базы знаний и промптинга, проанализированы требования к подготовке данных и способы представления знаний: от атомарных единиц с глоссарием и рубрикаторм до графов знаний и онтологий.

В проектной части разработан трёхэтапный конвейер обработки неоднородных документов. На этапе дистилляции мультимодальная модель PaddleOCR-VL-1.5 разделяет документ на типизированные атомарные сущности; выбор модели обоснован результатами на эталонном наборе OmniDocBench v1.5 и устойчивостью к физическим искажениям документов. На этапе структуризации большие языковые модели формируют глоссарий, атомарные единицы знания и тематический рубрикатор. Спроектировано ролевое взаимодействие агентов с базой знаний, разделяющее функции поиска и анализа между агентом-библиотекарем и агентом-исследователем.

В практической части реализовано веб-приложение для подготовки данных и проведена апробация головного этапа конвейера на двух

профессиональных руководствах со сложной вёрсткой, BABOK и PMBOK, в русском и английском изданиях.

В ходе работы получены следующие результаты:

- обработаны два руководства, BABOK и PMBOK, в русском и английском изданиях, суммарным объёмом более 2600 страниц;
- документ разделяется на сущности трёх типов: текстовые блоки, изображения и таблицы;
- результаты выгружаются в трёх форматах, пригодных для дальнейшей обработки;
- спроектирована ролевая схема из двух специализированных агентов;
- развёрнут демонстрационный сценарий вопросно-ответного взаимодействия с базой знаний, в котором ответы сопровождаются ссылками на фрагменты источника.

Главным содержательным выводом апробации является то, что узким местом системы выступает не этап распознавания, а этап структуризации. Навигация по извлечённым сущностям, приоритизация контекста и маршрутизация материалов между агентами требуют дополнительной проработки. Этот вывод определяет приоритеты дальнейшей работы.

Полученные результаты могут применяться для построения персонализированных баз знаний для организаций и частных пользователей. Дальнейшее развитие системы предполагает массовую обработку полных массивов документов, переход к графовому представлению знаний, расширение состава модальностей за счёт аудио- и видеоматериалов, а также развитие расширяемой агентной архитектуры с перспективой превращения решения в самостоятельный программный продукт.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Гудфеллоу, Я. Глубокое обучение / Я. Гудфеллоу, И. Бенджио, А. Курвилль ; пер. с англ. А. А. Слинкина. – 2-е изд., испр. – Москва : ДМК Пресс, 2018. – 654 с. – ISBN 978-5-97060-618-6.
2. Дидковский, Б. Р. Мультиагенты на основе больших языковых моделей: анализ прогресса и проблем / Б. Р. Дидковский, А. И. Григорьев // Научный аспект. – 2024. – № 6. – URL: <https://na-journal.ru/6-2024-informacionnye-tehnologii/12984-multiagenty-na-osnove-bolshih-yazykovyh-modelei-analiz-progressa-i-problem> (дата обращения: 24.05.2026).
3. Кушмуратов, С. И. Эффективность метода LoRA в задачах генерации текста на узбекском языке / С. И. Кушмуратов, Р. Р. Давронов // Universum: технические науки. – 2025. – № 6 (135). – URL: <https://7universum.com/ru/tech/archive/item/20391> (дата обращения: 11.05.2026).
4. Науменко, А. О. Технология RAG (Retrieval-Augmented Generation) как инновационный подход в LLM / А. О. Науменко // Вестник науки. – 2025. – Т. 5, № 8 (89). – С. 280–289. – URL: <https://cyberleninka.ru/article/n/tehnologiya-rag-retrieval-augmented-generation-kak-innovatsionnyy-podhod-v-llm> (дата обращения: 06.05.2026).
5. Невзорова, О. А. Система автоматического построения графов знаний математических документов / О. А. Невзорова, Б. Т. Гизатуллин // Ученые записки Казанского университета. Серия Физико-математические науки. – 2023. – Т. 165, кн. 3. – С. 264–281. – URL: <https://cyberleninka.ru/article/n/sistema-avtomaticheskogo-postroeniya-grafov-znaniy-matematicheskikh-dokumentov> (дата обращения: 18.05.2026).
6. Николенко, С. И. Глубокое обучение. Погружение в мир нейронных сетей : руководство / С. И. Николенко, А. А. Кадурын, Е. О. Архангельская. – Санкт-Петербург : Питер, 2019. – 480 с. – ISBN 978-5-496-02536-2.

7. Рассел, С. Искусственный интеллект: современный подход. В 3 томах. Т. 1. Решение проблем: знания и рассуждения / С. Рассел, П. Норвиг ; пер. с англ. – 4-е изд. – Санкт-Петербург : Диалектика, 2021. – 704 с. – ISBN 978-5-907365-25-4.

8. Роль больших языковых моделей в интегрированных средах разработки нового поколения / А. Ю. Ишанхонов, Д. В. Пшиченко, Е. А. Можаровский, А. С. Алуев // Программные системы и вычислительные методы. – 2024. – № 4. – С. 140–150. – URL: <https://cyberleninka.ru/article/n/rol-bolshih-yazykovyh-modeley-v-integrirrovannyh-sredah-razrabotki-novogo-pokoleniya> (дата обращения: 02.05.2026).

9. A Survey of Graph RAG for Customized Large Language Models / Q. Zhang, S. Chen, Y. Bei [и др.] // arXiv : [сайт]. – 2025. – arXiv:2501.13958. – URL: <https://arxiv.org/abs/2501.13958> (дата обращения: 20.05.2026).

10. A Survey of Personalized Large Language Models: Progress and Future Directions / J. Liu, Z. Qiu, Z. Li [и др.] // arXiv : [сайт]. – 2025. – arXiv:2502.11528. – URL: <https://arxiv.org/abs/2502.11528> (дата обращения: 16.05.2026).

11. An Information Distillation Framework for Extractive Summarization / K.-Y. Chen, S.-H. Liu, B. Chen, H.-M. Wang // IEEE/ACM Transactions on Audio, Speech, and Language Processing. – 2018. – Vol. 26, № 1. – P. 161–170. – DOI 10.1109/TASLP.2017.2764545.

12. Anthropic. Effective Context Engineering for AI Agents // Anthropic : [сайт]. – 2025. – URL: <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents> (дата обращения: 02.06.2026).

13. Attention Is All You Need / A. Vaswani, N. Shazeer, N. Parmar [и др.] // Advances in Neural Information Processing Systems 30 (NIPS 2017). – 2017. – P. 5998–6008. – URL: <https://arxiv.org/abs/1706.03762> (дата обращения: 03.05.2026).

14. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding / J. Devlin, M.-W. Chang, K. Lee, K. Toutanova // Proceedings of

the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT 2019). – 2019. – P. 4171–4186. – URL: <https://arxiv.org/abs/1810.04805> (дата обращения: 04.05.2026).

15. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models / J. Wei, X. Wang, D. Schuurmans [и др.] // Advances in Neural Information Processing Systems 35 (NeurIPS 2022). – 2022. – P. 24824–24837. – URL: <https://arxiv.org/abs/2201.11903> (дата обращения: 10.05.2026).

16. «Everyone wants to do the model work, not the data work»: Data Cascades in High-Stakes AI / N. Sambasivan, S. Kapania, H. Highfill [и др.] // Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems (CHI 2021). – 2021. – DOI 10.1145/3411764.3445518.

17. From Local to Global: A Graph RAG Approach to Query-Focused Summarization / D. Edge, H. Trinh, N. Cheng [и др.] // arXiv : [сайт]. – 2024. – arXiv:2404.16130. – URL: <https://arxiv.org/abs/2404.16130> (дата обращения: 21.05.2026).

18. Gartner. Lack of AI-Ready Data Puts AI Projects at Risk // Gartner : [сайт]. – 2025. – URL: <https://www.gartner.com/en/newsroom/press-releases/2025-02-26-lack-of-ai-ready-data-puts-ai-projects-at-risk> (дата обращения: 14.05.2026).

19. Generative Agents: Interactive Simulacra of Human Behavior / J. S. Park, J. C. O'Brien, C. J. Cai [и др.] // Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST 2023). – 2023. – URL: <https://arxiv.org/abs/2304.03442> (дата обращения: 30.05.2026).

20. Jurafsky, D. Speech and Language Processing : 3rd ed. draft / D. Jurafsky, J. H. Martin. – 2026. – URL: <https://web.stanford.edu/~jurafsky/slp3/> (дата обращения: 05.05.2026).

21. Language Models are Few-Shot Learners / T. B. Brown, B. Mann, N. Ryder [и др.] // Advances in Neural Information Processing Systems 33 (NeurIPS 2020). – 2020. – P. 1877–1901. – URL: <https://arxiv.org/abs/2005.14165> (дата обращения: 05.05.2026).

22. Lester, B. The Power of Scale for Parameter-Efficient Prompt Tuning / B. Lester, R. Al-Rfou, N. Constant // Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP 2021). – 2021. – P. 3045–3059. – URL: <https://arxiv.org/abs/2104.08691> (дата обращения: 13.05.2026).
23. LoRA: Low-Rank Adaptation of Large Language Models / E. J. Hu, Y. Shen, P. Wallis [и др.] // International Conference on Learning Representations (ICLR 2022). – 2022. – URL: <https://arxiv.org/abs/2106.09685> (дата обращения: 12.05.2026).
24. Lost in the Middle: How Language Models Use Long Contexts / N. F. Liu, K. Lin, J. Hewitt [и др.] // Transactions of the Association for Computational Linguistics. – 2024. – Vol. 12. – P. 157–173. – URL: <https://arxiv.org/abs/2307.03172> (дата обращения: 23.05.2026).
25. PaddleOCR-VL-1.5: Towards a Multi-Task 0.9B VLM for Robust In-the-Wild Document Parsing / C. Cui, T. Sun, S. Liang [и др.] // arXiv : [сайт]. – 2026. – arXiv:2601.21957. – URL: <https://arxiv.org/abs/2601.21957> (дата обращения: 11.06.2026).
26. ReAct: Synergizing Reasoning and Acting in Language Models / S. Yao, J. Zhao, D. Yu [и др.] // International Conference on Learning Representations (ICLR 2023). – 2023. – URL: <https://arxiv.org/abs/2210.03629> (дата обращения: 28.05.2026).
27. Reimers, N. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks / N. Reimers, I. Gurevych // Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP 2019). – 2019. – P. 3982–3992. – URL: <https://arxiv.org/abs/1908.10084> (дата обращения: 17.05.2026).
28. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks / P. Lewis, E. Perez, A. Piktus [и др.] // Advances in Neural Information Processing Systems 33 (NeurIPS 2020). – 2020. – P. 9459–9474. – URL: <https://arxiv.org/abs/2005.11401> (дата обращения: 06.05.2026).

29. Retrieval-Augmented Generation for Large Language Models: A Survey / Y. Gao, Y. Xiong, X. Gao [и др.] // arXiv : [сайт]. – 2023. – arXiv:2312.10997. – URL: <https://arxiv.org/abs/2312.10997> (дата обращения: 19.05.2026).

30. Scaling Laws for Neural Language Models / J. Kaplan, S. McCandlish, T. Henighan [и др.] // arXiv : [сайт]. – 2020. – arXiv:2001.08361. – URL: <https://arxiv.org/abs/2001.08361> (дата обращения: 07.05.2026).

31. Survey of Hallucination in Natural Language Generation / Z. Ji, N. Lee, R. Frieske [и др.] // ACM Computing Surveys. – 2023. – Vol. 55, № 12. – P. 1–38. – URL: <https://arxiv.org/abs/2202.03629> (дата обращения: 09.05.2026).

32. Training Language Models to Follow Instructions with Human Feedback / L. Ouyang, J. Wu, X. Jiang [и др.] // Advances in Neural Information Processing Systems 35 (NeurIPS 2022). – 2022. – P. 27730–27744. – URL: <https://arxiv.org/abs/2203.02155> (дата обращения: 08.05.2026).

ПРИЛОЖЕНИЕ А

Примеры представления атомарных сущностей

Ниже приведена целевая схема описания атомарной сущности базы знаний и примеры её заполнения для сущностей трёх типов: текстового блока, таблицы и изображения.

```
{
  "id": "babok-ru-p045-text-012",
  "type": "text",
  "source": "BABOK Guide, русское издание",
  "page": 45,
  "content": "Выявление требований проводится во
              взаимодействии с заинтересованными сторонами.",
  "category": "Выявление требований",
  "terms": ["заинтересованная сторона", "требование", "интервью"],
  "relations": ["babok-ru-p052-table-003", "babok-ru-p060-image-007"]
}

{
  "id": "babok-ru-p052-table-003",
  "type": "table",
  "source": "BABOK Guide, русское издание",
  "page": 52,
  "file": "tables/babok-ru-p052-table-003.csv",
  "caption": "Сравнение методов выявления требований",
  "category": "Методы анализа",
  "terms": ["метод выявления", "критерий выбора"],
  "relations": ["babok-ru-p045-text-012"]
}

{
  "id": "babok-ru-p060-image-007",
  "type": "image",
  "source": "BABOK Guide, русское издание",
  "page": 60,
  "file": "images/babok-ru-p060-image-007.png",
  "caption": "Схема жизненного цикла требований",
  "category": "Жизненный цикл требований",
  "terms": ["жизненный цикл требований"],
  "relations": ["babok-ru-p045-text-012"]
}
```

ПРИЛОЖЕНИЕ Б

Ролевые инструкции ИИ-агентов

Роли агентов задаются текстовыми инструкциями, которые передаются языковой модели при создании агента. Ниже приведены тексты инструкций агента-библиотекаря и агента-исследователя.

Роль: агент-библиотекарь.

Задача: по запросу пользователя найти в базе знаний релевантные сущности и подготовить подборку источников.

Правила:

1. Ищи сущности по смысловой близости и по рубрикам.
2. Отбрасывай фрагменты, не относящиеся к запросу.
3. Упорядочивай отобранное от общего к частному.
4. Не формируй содержательный ответ: твой результат – список сущностей с идентификаторами и краткими пояснениями, чем каждая из них полезна.

Роль: агент-исследователь.

Задача: на основе подборки сущностей, подготовленной библиотекарем, построить ответ на запрос пользователя.

Правила:

1. Используй только переданные сущности; не привлекай собственные знания без явной пометки.
2. Сопровождай каждое утверждение ссылкой на идентификатор сущности и номер страницы источника.
3. Если переданных материалов недостаточно для ответа, сообщи об этом и сформулируй уточняющий запрос к библиотекарю.